

Proyecto 1: Organización de Archivos

1- Logro del estudiante

Entender y aplicar los algoritmos de almacenamiento de archivos físicos y [acceso concurrente].

2- Enunciado

En grupos máximo de cinco integrantes, elegir un dominio de datos conformado por al menos dos archivos planos con datos reales (<https://www.kaggle.com/datasets>). Luego sobre ellos implementar tres técnicas de organización de archivos con sus principales operaciones: inserción, eliminación y búsqueda.

3- Requerimientos generales

- a. Implementar tres de las siguientes técnicas de organización de archivos en memoria secundaria.
 1. Sequential File / AVL File
 2. ISAM-Sparse Index / B+ Tree
 3. Extendible Hashing
- b. Operaciones que se deben implementar:
 1. La búsqueda específica puede retornar más de un elemento que coincide con la key
`vector<Registro> search(T key)`
 2. La búsqueda por rango retorna todos los registros que se encuentran entre las dos llaves de búsqueda
`vector<Registro> rangeSearch(T begin-key, T end-key)`
 3. Agregar un registro al archivo respetando la técnica de organización
`bool add(Registro registro)`
 4. Proponer un algoritmo de eliminación para cada técnica
`bool remove(T key)`
- c. Implementar un parser de código SQL a sentencias ejecutables. Ejemplos de sentencias:
 - `create table Customer from file "C:\data.csv" using index hash("DNI")`
 - Definir las estructuras del registro previamente en el código.
 - `select * from Customer where DNI = x`
 - `select * from Customer where DNI between x and y`
 - `insert into Customer values (...)`
 - `delete from Customer where DNI = x`
- d. Mostrar los resultados de forma amigable a usuario. Ver la siguiente GUI de referencia.

Mi SGBD

Tables

Customer

Order

insert into table Order from file('C:\data.csv') using index hash;

select * from Order;

Result

Explain

Transx

Order ID	Customer ID	Quantity	Ship City	Ship Country	Is Closed	OrderDate
10000	FRANS	44	Graz	Austria	<input type="checkbox"/>	6/21/2011 12:00:00 AM
10001	FRANS	52	Resende	Brazil	<input type="checkbox"/>	11/3/2012 12:00:00 AM
10002	FRANS	47	Montréal	Canada	<input checked="" type="checkbox"/>	6/15/2011 12:00:00 AM
10003	FRANS	28	Graz	Austria	<input type="checkbox"/>	11/3/2011 12:00:00 AM
10004	MEREP	53	Buenos Aires	Argentina	<input type="checkbox"/>	5/26/2011 12:00:00 AM
10005	MEREP	26	Montréal	Canada	<input checked="" type="checkbox"/>	1/1/2012 12:00:00 AM
10006	MEREP	20	Graz	Austria	<input type="checkbox"/>	9/5/2011 12:00:00 AM
10007	MEREP	27	Buenos Aires	Argentina	<input type="checkbox"/>	4/6/2011 12:00:00 AM
10008	FOLKO	59	Buenos Aires	Argentina	<input checked="" type="checkbox"/>	7/7/2012 12:00:00 AM
10009	FOLKO	33	Montréal	Canada	<input type="checkbox"/>	4/23/2011 12:00:00 AM
10010	FOLKO	47	Graz	Austria	<input type="checkbox"/>	1/20/2012 12:00:00 AM

Table Order

10000 records

1.5 sec

4- Consideraciones de la implementación

- En el Sequential Index La función add(Registro registro)** debe utilizar un espacio auxiliar para guardar los nuevos registros. Cuando el espacio auxiliar llegue a K registros, aplique un algoritmo de reconstrucción del archivo de datos manteniendo el orden físico de acuerdo a la llave seleccionada. Asegúrese de mantener los punteros actualizados.
- En el ISAM** partir construyendo el índice estático hasta de 3 niveles a partir de un conjunto de datos. Para nuevas inserciones se generan los overflow pages (encadenamiento de páginas).
- En el ISAM** de debe definir el factor de bloque tanto en las páginas de datos como en las páginas del índice.
- La función **rangeSearch** debe usar el índice para buscar el begin-key y luego recorrer los registros de acuerdo la estructura del índice. Esta función no es soportada por las técnicas de hashing.
- Use adecuadamente los conceptos de programación orientado a objetos y programación genérica para que el programa soporte cualquier dominio de datos.
- Para la interfaz gráfica pueden usar QT, Visual Studio C++, wxWidgets u otra librería gráfica.

5- Informe del proyecto

- Archivo en Markdown / Wiki.
- Ortografía y consistencia en los párrafos.
- Al final del informe poner el **video explicando** el funcionamiento del programa, casos de uso, aspectos importantes de la implementación. El video no debe exceder los 10 minutos y deben participar todos los integrantes del grupo.

- Aspectos de evaluación e informe:

Item	Descripción
- Introducción (2 pts)	<ul style="list-style-type: none"> - Objetivo del proyecto. - Descripción del dominio de datos a usar. - Resultados que se esperan obtener al aplicar las técnicas de indexación.
- Técnicas Utilizadas. (9 pts)	<ul style="list-style-type: none"> - Describa brevemente las técnicas de indexación de archivos que ha elegido. - Explique el algoritmo de inserción, eliminación y búsqueda (use gráficos para un mayor entendimiento) - Se debe realizar un análisis comparativo teórico de las técnicas implementadas en base a los accesos a memoria secundaria tanto para las operaciones de inserción, búsqueda y eliminación. - En el código debe estar optimizado en el manejo de memoria secundaria. - Explicar claramente como se realizó el parser del SQL.
- Resultados Experimentales (5 pts)	<ul style="list-style-type: none"> - Cuadro y/o gráfico comparativo de desempeño de las técnicas de indexación de archivos sobre el dominio de datos. Tanto para inserción como para búsqueda. - Considerar dos métricas: total de accesos a disco duro (read & write) y tiempo de ejecución en milisegundos. - Discusión y análisis de los resultados experimentales.
- Pruebas de uso y presentación (4 pts)	<ul style="list-style-type: none"> - Presentar las pruebas de uso de la aplicación en interfaz gráfica amigable e intuitiva. - Recuerde mostrar la funcionalidad del aplicativo en el video.

6- Entregable

- Los alumnos formarán grupos de máximo cinco integrantes.
- El código fuente del proyecto será alojado en GitHub Classroom.
- En el Canvas subir solo el **enlace público** del proyecto.
- La fecha límite de entrega es el 13 de Mayo de 2024.